


## Devoir maison II

*Exercice 1.*

On suppose  $y = f + \xi$  avec  $\xi$  vecteur  $\sigma$ -SG. Soient  $\Theta \subseteq \mathbf{B}_1(L) := \{\theta : |\theta|_1 \leq L\}$ ,  $\tilde{f} := X\hat{\theta}^{\text{MC}}(\Theta)$  et  $\delta \in ]0; 1[$  fixé.

Montrer qu'avec une probabilité d'au moins  $1 - \delta$ , on a l'inégalité suivante:

$$\forall f \in \mathbb{R}^n : \|\tilde{f} - f\|^2 \leq \inf_{\theta \in \Theta} \|X\theta - f\|^2 + U_\delta$$

où  $U_\delta$  désigne un terme indépendant de  $f$  et que l'on précisera.

*Solution 1.*

Par le lemme 1.1, on a

$$\forall f \in \mathbb{R}^p, \forall \theta \in \Theta \quad \|\tilde{f} - f\|^2 \leq \|f - X\theta\|^2 + 2(\xi | \tilde{f} - X\theta)$$

Concentrons nous sur le terme de gauche. En utilisant la relation  $\tilde{f} := X\hat{\theta}^{\text{MC}}$  et en notant  $\hat{\theta} := \hat{\theta}^{\text{MC}}(\Theta)$ , on a successivement

$$(\xi | \tilde{f} - X\theta) = (X^T \xi | \hat{\theta} - \theta) \leq \frac{1}{n} \sum_{j=1}^p [X^T \xi]_j (\hat{\theta}_j - \theta_j) \leq \frac{1}{n} \max_{1 \leq j \leq p} |x_j^T \xi| \cdot |\hat{\theta} - \theta|_1$$

avec  $x_j$  désignant la  $j$ ème colonne de la matrice  $X$ . Comme  $\theta$  et  $\hat{\theta}$  appartiennent à  $\Theta \subseteq \mathbf{B}_1(L)$ , on a par inégalité triangulaire que  $|\hat{\theta} - \theta|_1 \leq 2L$ .

En introduisant  $v_j := \frac{x_j}{|x_j|_2}$  et  $x^\star := \max_{1 \leq j \leq p} \|x_j\| = \frac{1}{\sqrt{n}} \max_{1 \leq j \leq p} |x_j|_2$ , on a par ailleurs

$$\max_{1 \leq j \leq p} |x_j^T \xi| \leq \sqrt{n} x^\star \cdot \max_{1 \leq j \leq p} |v_j^T \xi|$$

Par définition de  $\xi$  vecteur  $\sigma$ -SG, on a  $v_j^T \xi$  variable  $\sigma$ -SG. On en déduit grâce au lemme 1.4 l'inégalité

$$\max_{1 \leq j \leq p} |v_j^T \xi| \leq \sigma \sqrt{2 \log\left(\frac{2p}{\delta}\right)}$$

vérifiée avec une probabilité d'au moins  $1 - \delta$ .

En posant  $U_\delta = 4\sigma L x^\star \sqrt{\frac{2 \log\left(\frac{2p}{\delta}\right)}{n}}$  on a donc avec une probabilité d'au moins  $1 - \delta$  l'inégalité suivante:

$$\forall f \in \mathbb{R}^p, \forall \theta \in \Theta \quad \|\tilde{f} - f\|^2 \leq \|f - X\theta\|^2 + U_\delta$$

Il suffit alors de prendre l'infimum sur  $\theta$  dans  $\Theta$  pour conclure.

---

**Exercice 2.**

Montrer que

$$\hat{\theta}^H = \operatorname{argmin}_{\theta \in \mathbb{R}^p} \left( \sum_{j=1}^p (Y_j - \theta_j)^2 + \tau^2 |\theta|_0 \right) \quad (1)$$

$$\hat{\theta}^S = \operatorname{argmin}_{\theta \in \mathbb{R}^p} \left( \sum_{j=1}^p (Y_j - \theta_j)^2 + 2\tau |\theta|_1 \right) \quad (2)$$

---

**Solution 2.**

(1) Notons  $\hat{\theta}$  un argmin de la fonction à minimiser. En réécrivant cette dernière, on a successivement:

$$\sum_{j=1}^p (Y_j - \theta_j)^2 + \tau^2 |\theta|_0 = \sum_{j=1}^p \left\{ (Y_j - \theta_j)^2 + \tau^2 \mathbb{1}_{\theta_j \neq 0} \right\} = \sum_{j=1}^p \psi(\theta_j, Y_j)$$

où  $\psi : \begin{cases} \mathbb{R}^2 & \mapsto \mathbb{R} \\ (\theta, Y) & \mapsto (Y - \theta)^2 + \tau^2 \mathbb{1}_{\theta \neq 0} \end{cases}$ .

Minimiser cette somme sur  $\theta$  à  $Y$  donné revient simplement à minimiser la fonction  $\psi$  à  $Y$  fixé et on aura  $\hat{\theta}_j = \operatorname{argmin}_{\theta \in \mathbb{R}} \psi(\theta, Y_j)$ .

On cherche à connaître la position relative de  $\psi(\theta, Y)$  par rapport à  $\psi(0, Y)$ :

$$\psi(\theta, Y) - \psi(0, Y) = (Y - \theta)^2 + \tau^2 - Y^2 = \theta^2 - 2Y\theta + \tau^2.$$

En posant  $\Delta' = Y^2 - \tau^2$ , les trois configurations suivantes sont alors possibles:

- $\Delta < 0$ , i.e.  $Y^2 < \tau^2$ . On a alors

$$\forall \theta \in \mathbb{R} - \{0\}, \quad \psi(\theta, Y) > \psi(0, Y).$$

L'argmin est donc unique et vaut 0.

- $\Delta = 0$ , i.e.  $Y^2 = \tau^2$ . On a alors

$$\forall \theta \in \mathbb{R} - \{0\}, \quad \psi(\theta, Y) - \psi(0, Y) = (\theta - Y)^2.$$

On a donc  $\theta = 0$  et  $\theta = Y$  qui minimisent la fonction objectif.

- $\Delta > 0$ , i.e.  $Y^2 > \tau^2$ . On a alors

$$\forall \theta \in ]Y - \sqrt{\Delta'}; Y + \sqrt{\Delta'}[, \quad \psi(\theta, Y) < \psi(0, Y).$$

Seul  $\theta = Y$  minimise  $\psi(\theta, Y) = (Y - \theta)^2 + \tau^2$  sur cet intervalle.

Finalement les coordonnées de  $\hat{\theta}_j^H := Y_j I(|Y_j| > \tau)$  vérifient bien les conditions obtenues ci-dessus<sup>1</sup>.

(2) Posons  $G(\theta) = \|\theta - Y\|^2 + 2\tau |\theta|_1$ . Par somme, on a bien  $G$  fonction convexe et l'équivalence suivante est vérifiée:

$$\hat{\theta} \in \operatorname{argmin}_{\theta \in \mathbb{R}^p} G(\theta) \iff 0 \in \partial G(\hat{\theta}). \quad (3)$$

Calculons la sous-différentielle de  $G$ :

$$\partial G(\theta) = 2(\theta - Y) + 2\tau \cdot \partial |\theta|_1$$

---

1. On aurait aussi pu choisir  $\hat{\theta}_j^H := Y_j I(|Y_j| \geq \tau)$  puisque l'argmin contient aussi  $Y$  lorsque  $Y^2 = \tau^2$ .

avec

$$\forall j \in \{1, \dots, p\} \quad (\partial |\theta|_1)_j = \begin{cases} \{\text{signe}(\theta_j)\}, & \text{si } \theta_j \neq 0 \\ [-1; 1], & \text{sinon} \end{cases}.$$

En utilisant 3, on en déduit donc:

$$\forall j \in \{1, \dots, p\} \quad \begin{cases} 0 = 2(\hat{\theta}_j - Y_j) + 2\tau \text{signe}(\hat{\theta}_j), & \text{si } \theta_j \neq 0 \\ 0 = 2(\hat{\theta}_j - Y_j) + 2\tau \alpha_j, & \text{sinon} \end{cases}.$$

avec  $|\alpha_j| \leq 1$  ce qui est équivalent à

$$\hat{\theta}_j = \begin{cases} Y_j - \tau, & \text{si } Y_j > \tau \\ 0, & \text{si } |Y_j| \leq \tau \\ Y_j + \tau, & \text{sinon} \end{cases}$$

pour tout  $j \in \{1, \dots, p\}$ . On retrouve bien l'expression attendue de l'estimateur de *soft-thresholding*  $\hat{\theta}_j^S := \left(1 - \frac{\tau}{|Y_j|}\right)_+ Y_j$ .

### Exercice 3.

Montrer que sous l'hypothèse ORT  $\left(\frac{1}{n} X^T \cdot X = I_p\right)$ , on a les égalités suivantes:

$$\hat{\theta}^D = \hat{\theta}^L = \hat{\theta}^S.$$

**Solution 3.** Rappelons la définition de chacun d'entre eux:

$$\hat{\theta}^S = \underset{\theta \in \mathbb{R}^p}{\operatorname{argmin}} \left( \sum_{j=1}^p (Y_j - \theta_j)^2 + 2\tau |\theta|_1 \right) \quad (4)$$

$$\hat{\theta}^L = \underset{\theta \in \mathbb{R}^p}{\operatorname{argmin}} \left( \|y - X\theta\| + 2\tau |\theta|_1 \right) \quad (5)$$

$$\hat{\theta}^D = \underset{\theta \in \mathbb{R}^p \text{ tq } \left| \frac{1}{n} X^T (y - X\theta) \right|_\infty \leq \tau}{\operatorname{argmin}} |\theta|_1 \quad (6)$$

- Montrons que  $\hat{\theta}^L = \hat{\theta}^S$ . En utilisant les relations  $\frac{1}{n} X^T \cdot X = I_p$  et  $Y = \frac{1}{n} X^T y$ , on a successivement:

$$\begin{aligned} \|y - X\theta\|^2 &= \frac{1}{n} \|y - X\theta\|_2^2 \\ &= \frac{1}{n} (y^T y - y^T X\theta - (X\theta)^T y + (X\theta)^T X\theta) \\ &= \frac{1}{n} y^T y - Y^T \theta - \theta^T Y + \theta^T \theta \\ &= \|Y - \theta\|_2^2 + C \end{aligned}$$

où  $C = \frac{1}{n} y^T y - Y^T Y$  indépendant de  $\theta$  variable d'optimisation.

Les deux fonctions objectifs définissant les estimateurs  $\hat{\theta}^L$  et  $\hat{\theta}^S$  ne différant que d'une constante, on a bien égalité de ces derniers<sup>2</sup>.

- Montrons que  $\hat{\theta}^D = \hat{\theta}^S$ . Commençons par réécrire la contrainte de Dantzig en terme de  $Y$ . Les conditions d'orthonormalité sur  $X$  et la relation  $Y = \frac{1}{n} X^T y$  nous permettent d'écrire:


$$\frac{1}{n} X^T (y - X\theta) = Y - \theta.$$

2. Les deux fonctions objectifs étant strictement convexes, on a bien unicité de ce dernier, son existence étant garanti par la coercivité des fonctions objectifs.

On doit donc montrer que

$$\hat{\theta}^S = \underset{\theta \in \mathbb{R}^p \text{ tq } |Y - \theta|_\infty \leq \tau}{\operatorname{argmin}} | \theta |_1.$$


Notons  $\hat{\theta}$  l'armin de la fonction ci-dessus. Minimiser  $| \theta |_1 = \sum_{j=1}^p | \theta_j |$  étant donné les contraintes indépendantes sur les  $\theta_i$  revient à résoudre le problème de minimisation ci-dessous pour  $p = 1$ , i.e. du type et illustrer figure 3:  $\underset{\theta \in \mathbb{R} \text{ tq } |Y - \theta| \leq \tau}{\operatorname{argmin}} | \theta |.$



On cherche à minimiser la valeur absolue de  $\theta$  sous la contrainte de ne pas s'éloigner de  $Y$  de plus d'un  $\tau$ .


Trois configurations sont alors possibles:

- $Y - \tau \geq 0$ :




Dans ce cas  $\hat{\theta} = Y - \tau$  minimise bien la valeur absolue.

- $Y + \tau \leq 0$ :



Dans ce cas  $\hat{\theta} = Y + \tau$  minimise bien la fonction objectif.

- $Y - \tau \leq 0$ :



Dans ce cas  $\hat{\theta} = 0$  est bien la valeur optimale.

Finalement, on a bien  $\hat{\theta}_j^D = \hat{\theta}_j^S$  pour tout  $j$  dans  $\{1, \dots, p\}$  ce qui conclut la preuve.

---

#### Exercice 4.

Soit  $y = X\theta^* + \xi$  avec  $\theta^*$  sparse. On suppose que les hypothèses d'orthogonalité de  $X \left( \frac{1}{n} X^T \cdot X = I_p \right)$  et de gaussianité du bruit :  $\xi \sim \mathcal{N}(0, \sigma^2 I_{n \times n})$ . On peut donc écrire:  $Y_j = \theta_j^* + \epsilon + \eta_j$  avec  $\epsilon = \frac{\sigma}{\sqrt{n}}$  et  $\eta_j \sim \mathcal{N}(0, 1)$ .

Soit  $\tau = A\sigma\sqrt{\frac{2\log(\frac{p}{\delta})}{n}}$  pour  $\delta \in ]0; 1[$  et  $A \geq 1$ . Montrer que l'on a avec une probabilité supérieure à  $1 - \delta$  l'inégalité d'oracle en probabilité suivante :

$$|\hat{\theta}^S - \theta^*|_2^2 \leq C \frac{\sigma^2}{n} |\theta^*|_0 \log\left(\frac{p}{\delta}\right).$$

---

#### Solution 4.

Comme pour l'estimateur de *hard-thresholding*, considérons l'évènement suivant :

$$\mathcal{A} := \left\{ \max |Y_j - \theta_j^*| \leq r \mid \forall j = 1 \dots p \right\}.$$

où  $r := \sigma\sqrt{\frac{2\log(\frac{p}{\delta})}{n}} = \epsilon\sqrt{2\log(\frac{p}{\delta})}$ . Procédons par étape:

- Montrons que  $\mathbb{P}(\mathcal{A}^C) \leq \delta$ . En utilisant la relation  $Y_j = \theta_j^* + \epsilon\eta_j$ , on a successivement:

$$\begin{aligned} \mathbb{P}(\mathcal{A}^C) &= \mathbb{P}\left(\max |Y_j - \theta_j^*| > r \mid \forall j = 1 \dots p\right) \\ &= \mathbb{P}\left(\max |Y_j - \theta_j^*| > \epsilon\sqrt{2\log\left(\frac{p}{\delta}\right)}\right) \\ &= \mathbb{P}\left(\max |\eta_j| > \sqrt{2\log\left(\frac{p}{\delta}\right)}\right) \leq \delta \end{aligned}$$

en vertu du lemme 2.3 a) <sup>4</sup>.


- Soient  $\hat{J} = \{j \text{ tq } \hat{\theta}_j^S \neq 0\} = \{j \text{ tq } |Y_j| > \tau\}$  <sup>5</sup>. Montrons que  $\hat{J} \subseteq J^*$  sur  $\mathcal{A}$ .

En effet, pour  $j \in \hat{J}$ , on a par inégalité triangulaire:

$$|\theta_j^*| \geq |Y_j| - |\theta_j^* - Y_j| = |Y_j| - |\epsilon\eta_j| \geq |Y_j| - r > \tau - Ar = 0.$$

- Reste maintenant à majorer  $|\hat{\theta}^S - \theta^*|_2$ . On a:

$$|\hat{\theta}^S - \theta^*|_2^2 = \sum_{j \in J^*} |\hat{\theta}_j^S - \theta_j^*|^2 + \sum_{j \notin J^*} |\hat{\theta}_j^S - \theta_j^*|^2.$$

  $\sum_{j \notin J^*} |\hat{\theta}_j^S - \theta_j^*|^2$ . Comme  $\hat{J} \subseteq J^*$ , on a  $(J^*)^C \subseteq (\hat{J})^C$ . D'où la nullité de cette somme.

  $\sum_{j \in J^*} |\hat{\theta}_j^S - \theta_j^*|^2$ . Faisons une disjonction de cas:

- Si  $|Y_j| > \tau$ , alors  $\hat{\theta}_j^S = Y_j \pm \tau = \theta_j^* + \epsilon\eta_j \pm \tau$ . On a donc la majoration:

$$|\hat{\theta}_j^S - \theta_j^*|^2 \leq (\epsilon|\eta_j| + \tau)^2 \leq 2(\epsilon^2\eta_j^2 + \tau^2).$$

---

3. On a alors la relation  $\tau = Ar$ .

4. Ceci est inchangé par rapport à la preuve avec l'estimateur de *hard-thresholding* puisqu'aucun estimateur n'intervient dans la définition de  $\mathcal{A}$ .

5. On rappelle que  $\hat{\theta}_j^S = \left(1 - \frac{\tau}{|Y_j|}\right)_+ Y_j$

- Si  $|Y_j| \leq \tau$ . Dans ce cas  $\hat{\theta}_j^S = 0$  et on a:

$$\left| \hat{\theta}_j^S - \theta_j^\star \right|^2 = \left| \theta_j^\star \right|^2 \leq \left( |Y_j| + \epsilon |\eta_j| \right)^2 \leq \left( \tau + \epsilon |\eta_j| \right)^2 \leq 2 \left( \epsilon^2 \eta_j^2 + \tau^2 \right).$$

Finalement, en utilisant  $|Y_j - \theta_j^\star| = |\epsilon \eta_j| \leq r$  sur  $\mathcal{A}$  et la relation  $\tau = Ar$ :

$$\begin{aligned} \left| \hat{\theta}^S - \theta^\star \right|_2^2 &\leq 2 \left| \theta^\star \right|_0 \left( \epsilon^2 \eta_j^2 + \tau^2 \right) \\ &\leq 2 \left| \theta^\star \right|_0 (r^2 + \tau^2) \\ &\leq 2 \left| \theta^\star \right|_0 (1 + A^2) r^2 \\ &\leq C \frac{\sigma^2}{n} \left| \theta^\star \right|_0 \log \left( \frac{p}{\delta} \right) \end{aligned}$$

où  $C = 4(1 + A^2)$  est une constante absolue, d'où le résultat.

---